


Методы отбора переменных

Как сократить число признаков
и сохранить полезную информацию



$d \rightarrow k$

Работу выполнили: Куракин Андрей и Андреев Данила

Задача: меньше признаков, достаточно информации

Выбираем подмножество исходных столбцов, а не новые координаты

01

Шум

Убрать признаки без полезной добавки.

02

Повторяющаяся информация

Не хранить несколько копий сигнала.

03

Стоимость и понятность

Упростить обучение, применение и объяснение.

$$X \in \mathbb{R}^{n \times d}, \quad y = (y_1, \dots, y_n)$$

n — объекты; d — исходные признаки

$$\mathcal{F} = \{1, \dots, d\}, \quad S \subseteq \mathcal{F}$$

$$S^* = \arg \min_{S \subseteq \mathcal{F}} Q(S)$$

Фиксируем модель. Ошибку оцениваем на отложенных данных.

Размер набора ограничиваем или задаём правило остановки.

Цель — компактная модель с приемлемым качеством. Рост точности не гарантирован.

Три семейства методов

Различие — в том, как отбор использует модель

01

Фильтры

Оценка каждого признака отдельно

Важность $I(x)$

- + Быстрый первичный отбор
- Не видят совместные эффекты

02

Обёртки

Качество модели на разных наборах

$S \rightarrow \text{модель} \rightarrow Q(S)$

- + Учитывают выбранную модель
- Много повторных обучений

03

Встроенные

Отбор во время обучения модели

Коэффициент = 0

- + Отбор и обучение вместе
- Зависят от модели и настроек

Фильтры: ранжируем по важности $I(x)$

$I(x)$ — важность признака; метрику выбираем сами, исходя из задачи

ROC-AUC

Бинарная классификация

R^2 с таргетом

Однофакторная регрессия

Information Value

Разделение классов по группам

$$I(x_1), I(x_2), \dots, I(x_d)$$

ТОР-k

Оставляем k лучших признаков

ПОРОГ

$$I(x_i) \geq \text{threshold}$$

плюс

Быстрое и понятное
первичное сокращение набора.

минус

Не учитывает совместные распределения
и специфику итоговой модели.

Минус фильтров: совместная информация не видна

Например, решили отобрать лучшие 5 признаков по ROC-AUC

Переменная	AUC
Feature_1	0.75
Feature_10	0.749
Feature_4	0.749
Feature_8	0.748
Feature_27	0.745
...	...

Матрица корреляций


	Feature_1	Feature_2	Feature_3	Feature_4	Feature_5
Feature_1		0,98	0,97	0,96	-0,96
Feature_2	0,98		0,99	0,98	-0,97
Feature_3	0,97	0,99		0,96	-0,98
Feature_4	0,96	0,98	0,96		-0,99
Feature_5	-0,96	-0,97	-0,98	-0,99	

Признаки несут в себе **одну и ту же** информацию!

Схематическая иллюстрация: в исходных двух таблицах названия признаков различаются.

Best subsets: проверяем все подмножества

Обучаем модель на каждом наборе и выбираем минимум заданного Q



$d = 3$: восемь наборов, включая пустой

Выделенный набор — условный победитель.

2^d

ВОЗМОЖНЫХ ПОДМНОЖЕСТВ

$2^{20} = 1\,048\,576$

наборов при $d = 20$

плюс


Минимум Q среди всех допустимых подмножеств.

минус

Экспоненциальная стоимость; риск подгонки к валидации.

Forward: добавляем по одному признаку

Стартуем с пустого набора; каждый раз выбираем лучшую добавку



Проверяем каждый ещё не выбранный признак вместе с текущим набором и заново обучаем модель.

плюс

Меньше проверок, чем у полного перебора;
на старте модели небольшие.

минус

Нельзя удалить ранее выбранное;
можно пропустить полезную комбинацию.

Backward: удаляем по одному признаку

Начинаем с полного набора и сравниваем все удаления по одному



После каждого пробного удаления переобучаем модель.
Принимаем лучшее удаление, если критерий Q уменьшается.

плюс

Вклад признака оценивается
в окружении остальных переменных.

минус

Тяжёлый старт с полным набором;
удалённый признак не возвращается.

Stepwise: добавляем и пересматриваем выбор

Forward + Backward: после добавления перепроверяем уже выбранные признаки



После каждого добавления проверяем возможные удаления.

Стоп: ни добавление, ни удаление не улучшает Q.

плюс

Можно пересматривать предыдущие решения.

минус

Больше обучений, чем у Forward; глобальный оптимум не гарантирован.

Встроенный отбор: Lasso-регуляризация

L1-регуляризация зануляет часть коэффициентов прямо во время обучения

$$\frac{1}{2n} \|y - \hat{y}\|_2^2 + \alpha \|\beta\|_1 \longrightarrow \min$$

X₁ $\beta_1 \neq 0$ **X₂** $\beta_2 \neq 0$ **X₃** $\beta_3 = 0$ **X₄** $\beta_4 = 0$

Схема: нулевой коэффициент исключает признак из прогноза.

плюс

Отбор и обучение совмещены;
получаем разреженную модель.

минус

Нужны масштабирование и настройка α ;
при связанных признаках выбор нестабилен.

Численный пример: четыре исходных признака

Линейная регрессия со свободным членом; учебные данные без шума

$$y = 10 + 2x_1 + x_2, \quad x_3 = 2x_1$$

ВАЛИДАЦИЯ: 4 СТРОКИ

x_1	x_2	x_3	x_4	y
-1	-1	-2	0	7
-1	1	-2	0	9
1	-1	2	0	11
1	1	2	0	13

Обучение: 8 строк

Все комбинации $x_1, x_2, x_4 = \pm 1$.
 x_3 всегда равен $2x_1$.

x_1, x_2 — полезные сигналы
 x_3 — точная копия информации
 x_4 — посторонний признак

Обучаем на 8 строках, сравниваем MSE на 4 валидационных строках.

Три шага: MSE уменьшается $5 \rightarrow 1 \rightarrow 0$

На каждом шаге выбираем набор с наименьшей MSE на валидации

0. Без признаков

Прогноз: 10, 10, 10, 10

Квадраты ошибок:
9, 1, 1, 9

$$(9 + 1 + 1 + 9) / 4 = 5$$

MSE

5

1. Выбираем x_1

Признак	MSE
x_1	1
x_2	4
x_3	1
x_4	5

MSE

1

2. Добавляем x_2

Добавка к x_1	MSE
+ x_2	0
+ x_3	1
+ x_4	1

Точный прогноз: 7, 9, 11, 13

MSE

0

А top-2 по R^2 выберет x_1 и x_3 : обе оценки 0,8, но MSE набора останется 1.

Python: настоящий двунаправленный Stepwise

400 объектов · 8 признаков · 300 train / 100 test · 5 фолдов

```

1 def Q(cols):
2     if not cols:
3         return baseline_cv_mse
4     cv_mse = -cross_val_score(
5         LinearRegression(), X_train[list(cols)],
6         y_train, cv=cv,
7         scoring="neg_mean_squared_error"
8     ).mean()
9     return cv_mse + 0.02 * len(cols)
10
11 selected, path = stepwise(X_train.columns, Q)

```

Новый набор: $x3_mix = 2x_1 + x_2 + 0,6u$; ещё 5 столбцов — шум.

Результат реального запуска

Шаг	Q
+ x3_mix	1,411
+ x1	1,375
+ x2	1,072
- x3_mix	1,053

После двух исходных сигналов смесь $x3_mix$ становится лишней.

Сравнение: качество и число признаков

Обычная MSE на 100 тестовых строках: меньше — лучше

Метод	Признаков	Test MSE
Без отбора	8	0,920
Фильтр R^2 , $k=2$	2	1,325
Best subsets	2	0,948
Forward	3	0,944
Backward	2	0,948
Stepwise	2	0,948
Lasso	5	0,928

Обёртки: одинаковый Q. Фильтр: $k = 2$. Lasso: α по CV.

8 → 2

**Компактнее,
но не точнее**

На этом тесте отбор
не улучшил MSE.
Качество осталось
близким.

Как выбрать метод и проверить результат

Выбор зависит от размера задачи, модели и допустимой стоимости поиска

1 Много признаков

Фильтр для первичного сокращения

2 Можно сравнивать наборы

Best subsets при малом d ;

Forward / Backward / Stepwise — вместо полного перебора

3 Нужна разреженная линейная модель

Lasso с настройкой регуляризации

Разделить данные



Отбор внутри train / CV



Один финальный тест

Отбираем полезную информацию, а не просто отдельные «сильные» признаки.