

Методы отбора признаков (Feature Selection)

Андреев Д, Куракин А

Основы машинного обучения

Содержание

- 1 Введение
- 2 Методы фильтрации (Filter)
- 3 Методы обёртки (Wrapper)
- 4 Встроенные методы (Embedded)
- 5 Функции потерь и информационные критерии оценки

Что такое отбор признаков?

Отбор признаков (feature selection) — процесс выбора оптимального подмножества релевантных признаков для построения модели машинного обучения.

Основные цели:

- преодоление «проклятия размерности»;
- устранение мультиколлинеарности;
- сокращение времени обучения;
- повышение интерпретируемости при сохранении (или улучшении) обобщающей способности.

Математическая постановка

Обучающая выборка: матрица объектов-признаков $X \in \mathbb{R}^{N \times D}$, целевая переменная $y_i \in \mathbb{Y}$, Для регрессии: $\mathbb{Y} \in \mathbb{R}$, для классификации: $\mathbb{Y} = 1, \dots, K$

Определим полное множество индексов исходных признаков как: $\Omega = 1, \dots, D$

Задача: найти оптимальное подмножество $S \subset \Omega$, $|S| = m < D$, минимизирующее эмпирический риск базового алгоритма обучения A :

$$S^* = \arg \min_{S \subset \Omega} \frac{1}{M} \sum_{i=1}^M \mathcal{L}(A(X_S^{train})_{x_m}, y_i)$$

на отложенной выборке, где X_S - усеченная матрица объектов размерности $N \times D$, $\mathcal{L}$ — функция потерь алгоритма, а M — размер валидационной выборки.

Полный перебор — 2^D вариантов (NP-трудная задача). На практике — эвристики трёх классов.

Методы фильтрации

Оценивают статистические свойства признаков **независимо** от финальной модели. Быстрые, используются как методы предварительной фильтрации .

Порог дисперсии (Variance Threshold)

Удаляем признак j , если $\sigma_j^2 = \frac{1}{N} \sum_{i=1}^N (x_{ij} - \mu_j)^2 < \tau$, $\mu_j = \frac{1}{N} \sum_{i=1}^N x_{ij}$

Корреляция Пирсона: Измеряет степень линейной связи между непрерывным признаком $x^{(j)}$ и непрерывной целевой переменной y :

$$r_j = \frac{\sum_{i=1}^I (x_i^j - \bar{x}^j)(y_i - \bar{y})}{\sqrt{\sum (x_i^j - \bar{x}^j)^2 \sum (y_i - \bar{y})^2}}.$$

χ^2 -критерий

Для категориальных признаков. Статистика на таблице сопряжённости:

$$\chi_j^2 = \sum_{u=1}^U \sum_{v=1}^V \frac{(O_{uv} - E_{uv})^2}{E_{uv}}$$

где O_{uv} - наблюдаемое число объектов, E_{uv} - ожидаемое число объектов при гипотезе о независимости.

Взаимная информация (Mutual Information)

Улавливает любые (в т. ч. нелинейные) зависимости:

$$I(X^{(j)}; Y) = \sum_{x \in X^{(j)}} \sum_{y \in Y} p(x, y) \ln \frac{p(x, y)}{p(x)p(y)}$$

Используют целевой алгоритм как функцию оценки подмножества. Точнее фильтров, но значительно дороже вычислительно.

- **Forward Stepwise Selection** — начинаем с пустого множества, жадно добавляем лучший признак.
- **Backward Stepwise Elimination** — начинаем с полного набора, жадно удаляем наименее полезный.
- **Recursive Feature Elimination (RFE)** — обучаем модель, ранжируем по $|w_j|^2$ (или важности), отсекаем худшие, повторяем.

Встроенные методы

Отбор происходит внутри процесса обучения модели.

L1-регуляризация (LASSO)

$$Q_{LASSO}(w) = \frac{1}{2N} \sum_{i=1}^N \left(y_i - \sum_{j=1}^D w_j x_{ij} \right)^2 + \lambda \sum_{j=1}^D |w_j| \rightarrow \min_w$$

Признаки с $w_j = 0$ исключаются.

Elastic Net

$$Q_{EN}(w) = \frac{1}{2N} \sum_{i=1}^N \left(y_i - \sum_{j=1}^D w_j x_{ij} \right)^2 + \lambda_1 \sum_{j=1}^D |w_j| + \lambda_2 \sum_{j=1}^D w_j^2 \rightarrow \min_w$$

Лучше работает с группами коррелированных признаков.

Функции потерь и информационные критерии оценки

Штрафуют за избыточную размерность модели:

$$\text{AIC} = 2d - 2 \ln(L_{\max})$$

$$\text{BIC} = d \ln(N) - 2 \ln(L_{\max}),$$

где d — число параметров, $L_{\max}$ — максимизированное значение функции правдоподобия.

Скорректированный R^2 :

$$R_{adj}^2 = 1 - (1 - R^2) \frac{N - 1}{N - d - 1}$$

Метрики стабильности отбора

Индекс Жаккара

$$J(S_1, S_2) = \frac{|S_1 \cap S_2|}{|S_1 \cup S_2|}$$

Индекс Кунчевой

Учитывает вероятность случайного совпадения:

$$I_K(S_1, S_2) = \frac{r \cdot D - d^2}{d \cdot (D - d)}$$

где $r = |S_1 \cap S_2|$ - размер пересечения подмножеств, d - их фикс мощность $|S_1| = |S_2| = d$. Диапазон: $[-1, 1]$.

- Breiman L. Random forests. Machine Learning, 2001.
- Guyon I. et al. Gene selection for cancer classification using SVM. ML, 2002.
- Kohavi R., John G. Wrappers for feature subset selection. AI, 1997.
- Tibshirani R. Regression shrinkage and selection via the lasso. JRSS B, 1996.
- Zou H., Hastie T. Regularization and variable selection via the elastic net. JRSS B, 2005.