


КУРС «ОСНОВЫ МАШИННОГО ОБУЧЕНИЯ»

Гауссовские процессы (GP- регрессия)

Басс Иван, Грищенко Илья



Основные определения

Гауссовский процесс

$$(f(x_1), \dots, f(x_n)) \sim \mathcal{N}(0, K)$$

набор $\{f(x)\}$, любой
конечный срез
которого —
гауссовский вектор

Ядро (ковариационная функция)

$$k(x, x') = \text{Cov}(f(x), f(x'))$$

Ковариация между 2-
мя элементами

Прайор $\rightarrow$ постериор

$$p(\theta | y) \propto p(y | \theta) p(\theta)$$

формула Байеса

Гиперпараметры

параметры ядра l , σ_f (форма/масштаб функции) и уровень шума наблюдений σ_n подбираются по данным .

ПОСТАНОВКА ЗАДАЧИ

Модель и применимость

Модель наблюдений

$$y_i = f(x_i) + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma_n^2)$$

Предположение

$$f \sim \mathcal{GP}(0, k_\theta)$$

Хотим найти распределение

$$p(f_* \mid y)$$

апостериорное распределение f

Где встречается такая
задача
Байесовская оптимизация


Геостатистика (кригинг)

Активное обучение

Робототехника, калибровка

Разные ядра — разные свойства функций


RBF



$$k(x, x') = \sigma_f^2 \exp\left(-\frac{(x - x')^2}{2l^2}\right)$$

- бесконечно гладкие траектории
- похожесть только по расстоянию
- разумный выбор «по умолчанию»


Linear



$$k(x, x') = \sigma_f^2 (xx' + 1)$$

- траектории — прямые линии
- = байесовская линейная регрессия
- когда ожидаем линейный тренд

Periodic



$$k(x, x') = \sigma_f^2 \exp\left(-\frac{2\sin^2(\pi|x - x'|/p)}{l^2}\right)$$

- строго периодические траектории
- период p — гиперпараметр
- сезонность, циклические процессы

Ядра можно складывать/перемножать: например Periodic + RBF даёт «периодичность с медленным дрейфом».

Постановка

Все случайные величины с нулевым средним и конечной дисперсией - гильбертово пространство

$$\langle X, Y \rangle := \text{Cov}(X, Y), \quad \|X\|^2 = \text{Var}(X)$$

y - набор случайных величин = векторы из гильбертова пространства

Задача: найти ближайший элемент к f^* из пространства всевозможных (относительно хороших) функций от y . Ответ на эту задачу - функция $g(y) = E(f^* | y)$

Ищем решение в виде $f^* = \mu^* + \Delta$, где $\mu^* \in \text{Lin}(y)$, $\Delta \perp y$ - разложение по пространству $\text{Lin}(y)$ (конечномерному) и ортогональному к нему

$$\text{Cov}(f_* - Ly, y) = 0 \implies L = K_* K_\sigma^{-1} \quad \mu_* = K_* K_\sigma^{-1} y$$

Применение гауссовости

Имеем $f^* = \mu^* + \Delta$, $\mu^* \in \text{Lin}(y)$, $\Delta \perp y$

Ищем $E(f^* | y)$

$$E(f^* | y) = E(\Delta | y) + E(\mu^* | y) = E(\Delta | y) + \mu^*$$

(y, Δ) - гауссовский вектор, раз так, то из некоррелированности следует независимость: $E(\Delta | y) = E(\Delta) = 0$

Значит условное ожидание - ближайший элемент линейного пространства

Дисперсия - по теореме Пифагора $\text{Var}(f_*) = \text{Var}(\mu_*) + \text{Var}(\Delta)$

Итог: поиск наилучшего приближения в бесконечномерном пространстве свёдя к поиску в конечномерном и выражается формулой $\mu_* = K_* K_\sigma^{-1} y$

АЛГОРИТМ

Шаг 1: построение блочной матрицы

K ($n \times n$)

$$K_{ij} = k(x_i, x_j)$$

строим ковариационную матрицу на обучающей выборке

$K_\sigma = K + \sigma^2 I$

$$K_\sigma = K + \sigma_n^2 I$$

добавление гауссовского шума

K^* ($m \times n$)

$$(K^*)_{ij} = k(x_{*i}, x_j)$$

ковариация обучающей и тестовой выборки

K^{**} ($m \times m$)

$$(K^{**})_{ij} = k(x_{*i}, x_{*j})$$

ковариация тестовой выборки

АЛГОРИТМ

Шаг 2: решаем СЛАУ

5. Решить линейную систему $n \times n$

$$K_{\sigma} \alpha = y$$

где n - размер обучающей выборки

6. Апостериорное среднее

$$\mu_* = K_* \alpha$$

7. Апостериорная дисперсия

$$\Sigma_* = K_{**} - K_* K_{\sigma}^{-1} K_*^T$$

априорная минус данные

Важно: все эти шаги выполняются один раз, но решение системы может быть трудоёмким.

Подбор гиперпараметров

Оценки максимального правдоподобия - общий случай

$$\hat{\theta} = \underset{\theta}{\operatorname{argmax}} \log L(\theta) = \underset{\theta}{\operatorname{argmax}} \sum_{i=1}^n \log p(y_i | \theta)$$

выбираем параметры, при которых уже увиденные данные наиболее вероятны

Для GP — считается в явном виде (без приближений):

$$\log p(y | \theta) = -\frac{1}{2} y^T K_{\sigma}^{-1} y - \frac{1}{2} \log |K_{\sigma}| - \frac{n}{2} \log 2\pi$$

первое слагаемое — качество подгонки; **второе** — штраф за сложность.

Численный расчёт по шагам

Данные: две обучающие точки $(x_1, y_1) = (0, 1)$, $(x_2, y_2) = (1, 2)$.

Тестовая точка: $x_* = 0.5$.

Модель: RBF ядро

Гиперпараметры: $\sigma_f = 1$, $\ell = 1$, $\sigma_n = 0.1$.

Попарные ковариации: $k(0, 0) = k(1, 1) = 1$, $k(0, 1) = k(1, 0) = e^{-1/2} \approx 0.6065$.

Матрица ядра с шумом ($\sigma_n^2 = 0.01$): $K_\sigma = K + \sigma_n^2 I = \begin{pmatrix} 1.0100 & 0.6065 \\ 0.6065 & 1.0100 \end{pmatrix}$.

Обратная матрица: $K_\sigma^{-1} = \begin{pmatrix} 1.5484 & -0.9298 \\ -0.9298 & 1.5484 \end{pmatrix}$.

Умножаем на $\mathbf{y} = (1, 2)^\top$: $\alpha = K_\sigma^{-1} \mathbf{y} = \begin{pmatrix} 1.5484 \cdot 1 - 0.9298 \cdot 2 \\ -0.9298 \cdot 1 + 1.5484 \cdot 2 \end{pmatrix} = \begin{pmatrix} -0.3112 \\ 2.1670 \end{pmatrix}$.

Численный расчёт по шагам

Ковариации тестовой точки с обучающими: $k(0.5, 0) = k(0.5, 1) = e^{-0.125} \approx 0.8825$.
 $K_* = \begin{pmatrix} 0.8825 & 0.8825 \end{pmatrix}$.

Среднее: $\mu_* = K_* \alpha = 0.8825 \cdot (-0.3112 + 2.1670) = 0.8825 \cdot 1.8558 \approx \boxed{1.638}$.

Априорная дисперсия в точке x_* : $K_{**} = k(0.5, 0.5) = \sigma_f^2 = 1$.

Считаем $K_\sigma^{-1} K_*^\top$: $K_\sigma^{-1} K_*^\top = \begin{pmatrix} 1.5484 & -0.9298 \\ -0.9298 & 1.5484 \end{pmatrix} \begin{pmatrix} 0.8825 \\ 0.8825 \end{pmatrix} = \begin{pmatrix} 0.5459 \\ 0.5459 \end{pmatrix}$.

Умножаем слева на K_* : $K_* K_\sigma^{-1} K_*^\top = 0.8825 \cdot (0.5459 + 0.5459) \approx 0.9635$.

Итоговая дисперсия: $\sigma_*^2 = K_{**} - K_* K_\sigma^{-1} K_*^\top = 1 - 0.9635 = 0.0365$.
 $\sigma_* = \sqrt{0.0365} \approx \boxed{0.191}$.

Расчёт среднего и дисперсии

```
def rbf_kernel(X1, X2, l, sigma_f):
    sqdist = (X1[:, None] - X2[None, :]) ** 2
    return sigma_f**2 * np.exp(-0.5 * sqdist / l**2)

def gp_posterior(kernel_fn, X_train, y_train, X_test, l, sigma_f, sigma_n):
    K = kernel_fn(X_train, X_train, l, sigma_f) + sigma_n**2 * np.eye(len(X_train))
    K_s = kernel_fn(X_test, X_train, l, sigma_f)
    K_ss = kernel_fn(X_test, X_test, l, sigma_f)

    alpha = np.linalg.solve(K, y_train) # K_sigma alpha = y
    mu = K_s @ alpha # mu* = K_* alpha
    cov = K_ss - K_s @ np.linalg.solve(K, K_s.T) # Sigma* = K** - K_* K_sigma^-1
    K_*^T
    return mu, cov
```

Преимущества и недостатки метода

Преимущества

- + Выдаёт и точечное значение и разброс
- + Хорошо работает на малых/средних выборках - регуляризация встроена через прайор
- + Гиперпараметры подбираются алгоритмически (максимальное правдоподобие)
- + Гибкость без ручного feature engineering — вся гипотеза сосредоточена в ядре
- + Точное (не приближённое) решение — одна линейная система

Недостатки

- Плохо масштабируется: $O(n^3)$ по времени, $O(n^2)$ по памяти — нужны аппроксимации при больших n
- Чувствителен к выбору ядра: неверная гипотеза портит и прогноз, и интервал
- только гауссовский шум
- В высокой размерности «похожесть по расстоянию» (RBF) страдает от проклятия размерности

СРАВНЕНИЕ

GP-регрессия и альтернативы

Критерий	GP-регрессия	Линейная / Ridge	Байесовская регрессия
Точность (гладкие зависимости, малые n)	Высокая + честный доверительный интервал	Низкая при нелинейности	Низкая при нелинейности
Масштабируемость по n	Слабая: $O(n^3)$	Отличная: $O(n)$	Отличная: $O(n)$ (но кубическая по числу признаков: $O(d^3)$)
Устойчивость на малых данных	Высокая (регуляризация из прайора)	Средняя	Высокая (благодаря априорному распределению)
Выразительность без feature engineering	Высокая — форма задаётся ядром	Низкая — нужны ручные признаки	Низкая — нужны ручные признаки

ИСТОЧНИКИ

<https://gaussianprocess.org/gpml/chapters/>

<https://distill.pub/2019/visual-exploration-gaussian-processes/>

<https://www.mql5.com/ru/articles/18427>

Спасибо за внимание

Вопросы?

